

CLASSIFICAÇÃO DA QUALIDADE DOS VINHOS COM MACHINE LEARNING

RELATÓRIO TÉCNICO EXECUTIVO - TECH CHALLENGE FASE 2

Data: agosto de 2026

Elaborado por: Alessandra da Silva Ramos,
Beatriz Rosa Pizani,
Fabio Eiji Kato,
Pamela Vilar Coelho e
Vinícius Prado Costa

Instituição: FIAP POSTECH – Data Analytics (14DTAT)

CLASSIFICAÇÃO DA QUALIDADE DOS VINHOS COM MACHINE LEARNING

RELATÓRIO TÉCNICO EXECUTIVO - TECH CHALLENGE FASE 2

Relatório técnico executivo apresentado como requisito parcial para a obtenção de nota na Fase 2 do curso de Pós-Graduação FIAP POSTECH – Data Analytics (Turma 14DTAT).

Vídeo de Apresentação:

https://www.youtube.com/watch?v=68PQ212Fk_I

GitHub: <https://github.com/pamvilar/fiap-tech-challenge-fase2-14dtat>

Sumário

1. INTRODUÇÃO E OBJETIVOS DO PROJETO.....	4
2. ANÁLISE EXPLORATÓRIA DE DADOS (EDA) E DIAGNÓSTICO DO DATASET	5
3. TRATAMENTO DE DADOS E ESTRATÉGIA DE PRÉ-PROCESSAMENTO	6
4. METODOLOGIA DE MODELAGEM E ARQUITETURA DE TESTES.....	7
5. PERFORMANCE COMPARATIVA DOS MODELOS DE MACHINE LEARNING	7
6. MERGULHO TÉCNICO: MODELOS AVALIADOS E METODOLOGIA	8
7. DETERMINANTES DE QUALIDADE E INSIGHTS PREDITIVOS	11
8. CONCLUSÃO E RECOMENDAÇÕES ESTRATÉGICAS	12
9. BIBLIOGRAFIA E REFERÊNCIAS TÉCNICAS.....	13

1. INTRODUÇÃO E OBJETIVOS DO PROJETO

A produção das variantes tintas do "Vinho Verde" português enfrenta o desafio crítico de manter a consistência sensorial em larga escala. Tradicionalmente, a validação de qualidade depende de processos humanos subjetivos, como painéis de degustação, o que limita a escalabilidade operacional e introduz variabilidade indesejada nos lotes comerciais. Este projeto visa transitar para uma abordagem puramente baseada em dados físico-químicos objetivos para prever de forma automatizada e reproduzível a percepção de qualidade sensorial estabelecida por especialistas.

O objetivo central deste trabalho reside no desenvolvimento e validação técnica de um modelo preditivo robusto que seja capaz de classificar os vinhos em categorias de qualidade. Do ponto de vista técnico, o principal desafio é lidar com um conjunto de dados de dimensões reduzidas e um forte desbalanceamento de classes, onde apenas 13,46% das amostras pertencem à classe de alta qualidade. A camada estratégica desta transição tecnológica consiste em aumentar a eficiência da cadeia de suprimentos: a identificação precoce de lotes de alta qualidade permite realizar uma precificação diferenciada, além de proteger a reputação da marca por meio de um controle de qualidade preventivo e preditivo, em vez de reativo.




DIAGRAMA DE FLUXO DE VALIDAÇÃO DE QUALIDADE PREDITIVA PARA VINHO VERDE

2. ANÁLISE EXPLORATÓRIA DE DADOS (EDA) E DIAGNÓSTICO DO DATASET

A etapa de exploração diagnóstica foi fundamental para mapear as complexidades inerentes à estrutura química dos dados e definir as fronteiras de decisão dos modelos. O conjunto de dados original compreende 11 variáveis preditoras e a variável alvo (quality), que representa a nota de qualidade atribuída por especialistas em uma escala de 0 a 10.

Estruturalmente, as variáveis físico-químicas do conjunto de dados podem ser classificadas em quatro perfis:

- **Perfil de Acidez:** compreende a acidez fixa (fixed acidity), acidez volátil (volatile acidity) e o ácido cítrico (citric acid).
- **Compostos Químicos:** representados pelo açúcar residual (residual sugar), cloretos (chlorides) e sulfatos (sulphates).
- **Conservantes e Voláteis:** representados pelo dióxido de enxofre livre (free sulfur dioxide) e dióxido de enxofre total (total sulfur dioxide).
- **Propriedades Físicas:** representadas pela densidade (density), pH e teor alcoólico (alcohol).

No diagnóstico de qualidade de dados, foi detectada a presença de 125 registros duplicados na base de dados WineQT. Esses registros foram prontamente removidos na fase inicial para evitar contaminação por vazamento de dados (data leakage) e mitigar o risco de sobreajuste (overfitting). Com a eliminação dessas duplicatas, o universo amostral único reduziu de 1.143 para 1.018 amostras. A variável alvo original (quality) demonstrou um forte desbalanceamento, concentrando-se pesadamente nas notas intermediárias 5 (433 amostras) e 6 (409 amostras), enquanto as notas de alta qualidade 7 (122 amostras) e 8 (15 amostras) formam a classe minoritária.

Nossos diagnósticos estatísticos revelaram uma variância acentuada e a presença de outliers críticos em variáveis-chave. Notoriamente, o dióxido de enxofre total apresentou um valor máximo de 289,00 contra uma média amostral de 46,00. Paralelamente, a variável de cloretos (chlorides) registrou um máximo de 0,61 contra uma média de 0,09. No campo das correlações lineares, o teor alcoólico (alcohol) demonstrou a maior relação positiva direta com a variável alvo de qualidade (coeficiente de 0,49), ao passo que a acidez volátil

(volatile acidity) apresentou uma forte correlação linear negativa (-0.41). Isso indica quimicamente que a presença de acidez volátil elevada (que remete ao vinagre) deprecia severamente a percepção de qualidade do vinho.

3. TRATAMENTO DE DADOS E ESTRATÉGIA DE PRÉ-PROCESSAMENTO

A arquitetura de pré-processamento de dados foi desenhada sob o rigor metodológico de que a qualidade da saída preditiva é estritamente dependente da integridade e do tratamento adequado do sinal de entrada.

Dada a alta concentração de outliers em variáveis críticas como cloretos e dióxido de enxofre total, descartamos o uso de normalização padrão (StandardScaler) ou MinMax. Em seu lugar, implementamos o RobustScaler. Este método realiza o escalonamento utilizando a mediana e o intervalo interquartil (IQR), o que impede que os outliers distorçam as novas escalas de aprendizado dos modelos, preservando ao mesmo tempo a informação intrínseca contida nos limites superiores e inferiores das variáveis químicas.

Para alinhar o modelo preditivo às reais decisões estratégicas de negócio, a escala original da variável quality (que variava de 3 a 8) foi transformada em uma classificação binária:

- **Classe 1 (Alta Qualidade):** compreende vinhos com notas de qualidade maior ou igual a 7 (13,46% da base).
- **Classe 0 (Baixa/Média Qualidade):** compreende vinhos com notas de qualidade inferior a 7 (86,54% da base).

A separação do conjunto de dados foi realizada aplicando o seguinte protocolo de divisão: 80% das amostras foram alocadas para o treinamento dos modelos de aprendizado de máquina e 20% para a fase de testes e validação. De modo a garantir que o modelo não ignorasse as características químicas da classe minoritária, utilizamos o parâmetro de estratificação (stratify=y). Esse ajuste garantiu que a proporção exata de 86,54% de vinhos de Baixa/Média Qualidade e 13,46% de vinhos de Alta Qualidade fosse fielmente preservada tanto no conjunto de treino quanto no de teste, gerando partições estatisticamente válidas e balanceadas.

4. METODOLOGIA DE MODELAGEM E ARQUITETURA DE TESTES

A arquitetura de testes envolveu o treinamento e a exaustiva comparação de múltiplos algoritmos de classificação, buscando mapear desde relações lineares simples até interações e dependências complexas e não-lineares. Foram avaliados os seguintes modelos:

- **Modelos de Margens e Lineares:** Regressão Logística e Support Vector Classifier (SVC).
- **Modelos Baseados em Árvores e Ensembles:** Decision Tree, Random Forest, Gradient Boosting e XGBoost.
- **Modelos Probabilísticos e de Vizinhança:** Gaussian Naive Bayes e K-Neighbors Classifier (KNN).

Para mitigar o severo desbalanceamento de classes, aplicou-se o hiperparâmetro de balanceamento automático de pesos (`class_weight='balanced'`) no SVC e no Random Forest. Estrategicamente, o foco analítico do projeto afastou-se da acurácia nominal simples (considerada uma métrica de vaidade em dados desbalanceados) e concentrou-se na otimização do Recall (Sensibilidade) e do F1-Score da Classe 1. No cenário produtivo de vinhos finos, o maior valor de negócio reside na capacidade de identificar corretamente e com segurança a excelência, minimizando a incidência de falsos negativos.

5. PERFORMANCE COMPARATIVA DOS MODELOS DE MACHINE LEARNING

Os resultados operacionais no conjunto de testes de 204 amostras revelam um claro trade-off entre a acurácia global e a sensibilidade do modelo de classificação para a classe de Alta Qualidade (Classe 1), conforme detalhado na tabela abaixo:

Modelo	Acurácia	F1-Score (Classe 1)	Observações Clínicas / Operacionais
Decision Tree (max_depth=5)	88,24%	0,40	Acurácia global alta, mas recall de apenas 30% na classe Premium.
Gradient Boosting	87,75%	0,42	F1-Score real de 0,42 e Recall de 33%. Sinais de sobreajuste entre treino e teste.
Random Forest (balanced)	87,75%	0,49	Melhor equilíbrio. F1-Score de 49% e Recall de 44% com pesos balanceados.
Gaussian Naive Bayes	85,78%	0,57	Maior sensibilidade (Recall de 70%) para classe Premium.
SVC (Scaled)	81,86%	0,51	Sólido equilíbrio de classe, porém com perda de acurácia global.
Regressão Logística	78,92%	0,48	Desempenho limitado devido à incapacidade de capturar relações não-lineares.
KNN (k=26)	89,22%	0,39	Maior acurácia nominal, mas recall baixíssimo de 26%.
XGBoost	87,25%	0,38	Recall baixo (30%) e F1-Score abaixo do Random Forest.

Tabela 1: Comparativo de Performance dos Modelos (Base de Teste - 204 amostras)

A análise estratégica da performance comparativa revela que modelos com acurácia nominal mais alta (como KNN com 89,22% e Decision Tree com 88,24%) são na verdade prejudicados pelo desbalanceamento de classes, mostrando-se incapazes de classificar os vinhos finos (Recalls de apenas 26% e 30%, respectivamente). Em contrapartida, o Gaussian Naive Bayes oferece a maior sensibilidade para detecção de vinhos premium (Recall de 70%), enquanto o Random Forest oferece o melhor equilíbrio geral para implantação em ambiente real, com um F1-Score de 49% e precisão robusta de 55% para a classe minoritária.

6. MERGULHO TÉCNICO: MODELOS AVALIADOS E METODOLOGIA

A remoção de registros duplicados reduziu o conjunto de dados para 1.018 amostras únicas, o que tecnicamente inviabiliza abordagens de Deep Learning e direciona a escolha metodológica para modelos tradicionais baseados em árvores e ensembles.

6.1 O Modelo Decision Tree

O Decision Tree Classifier foi configurado utilizando a entropia como critério de divisão de nós, maximizando o ganho de informação a cada partição. Para evitar o sobreajuste e garantir que o modelo não memorizasse o reduzido conjunto de dados, a profundidade máxima foi limitada a 5 camadas ($\text{max_depth}=5$). Apesar da acurácia global satisfatória de 88,24%, o modelo revelou-se extremamente conservador devido ao desbalanceamento da base. Conforme a matriz de confusão, o modelo acertou 172 das 177 amostras de vinhos comuns (Verdadeiros Negativos), mas identificou apenas 8 dos 27 vinhos de alta qualidade (Verdadeiros Positivos), gerando 19 falsos-negativos e um Recall sofrível de apenas 30%.



6.2 O Modelo Gradient Boosting

O Gradient Boosting Classifier foi parametrizado com 100 estimadores e learning_rate de 0,1. O modelo funciona por meio da minimização sucessiva de resíduos (erros) das árvores anteriores. Este modelo alcançou uma acurácia no teste de 87,75%, porém com sinais claros de overfitting (acurácia de 97,05% no treinamento, um gap de 9,30 pontos percentuais). A análise detalhada da matriz de confusão real na base de teste revela um total de 179 acertos (170 Verdadeiros Negativos e 9 Verdadeiros Positivos), ocorrendo 7 Falsos Positivos e 18 Falsos Negativos. O F1-Score do Gradient Boosting para a classe Premium foi de 0,42, e o Recall real de 33,33% aponta que o modelo desconsidera a maior parte da classe minoritária.



6.3 O Modelo Random Forest

O Random Forest Classifier foi configurado com 100 estimadores ($n_estimators=100$) e o parâmetro de balanceamento `class_weight='balanced'`. Esta parametrização ajusta os pesos das classes de forma inversamente proporcional às suas frequências na base de dados, forçando o algoritmo a dar a devida relevância aos raros vinhos de Alta Qualidade durante a fase de treinamento. No conjunto de testes, o Random Forest alcançou uma acurácia de 87,75%.

Sua matriz de confusão na base de teste de 204 amostras apresentou resultados muito superiores sob a ótica operacional de negócio: obteve 179 acertos totais, sendo 167 Verdadeiros Negativos (vinhos comuns classificados corretamente) e 12 Verdadeiros Positivos (vinhos finos identificados). O modelo registrou apenas 10 Falsos Positivos e 15 Falsos Negativos. Isso resultou em um Recall de 44% e em um F1-Score robusto de 49% (0,49 na escala decimal, corrigindo distorções prévias de unidade).



A robustez intrínseca do algoritmo de Random Forest, que utiliza múltiplas árvores independentes, o consolidou como o modelo mais equilibrado e com menor risco de generalização para o pipeline de produção.

7. DETERMINANTES DE QUALIDADE E INSIGHTS PREDITIVOS

A identificação das características físico-químicas determinantes para a classificação de vinhos de Alta Qualidade uniu o rigor dos modelos matemáticos à engenharia enológica real. Tanto o Gradient Boosting quanto o Random Forest convergiram ao apontar as três variáveis mais decisivas para a predição, listadas a seguir em ordem de importância:

- **Teor Alcoólico (Alcohol):** Relevância de 0,3159. Quimicamente, o álcool confere corpo, viscosidade e equilíbrio sensorial ao vinho Verde, sendo o principal divisor de águas entre lotes comuns e premium.
- **Sulfatos (Sulphates):** Relevância de 0,1532. Os sulfatos agem como antioxidantes e conservantes fundamentais, e sua calibração exata está fortemente relacionada à preservação do frescor e estabilidade do vinho.
- **Acidez Volátil (Volatile Acidity):** Relevância de 0,1485 (com impacto negativo). A acidez volátil indica a presença de ácido acético (vinagre). Teores elevados depreciam severamente o produto.

O mapeamento de dados revela que os vinhos classificados como Alta Qualidade (notas 7 e 8) possuem mediana de teor alcoólico acima de 11,5%, enquanto vinhos de Baixa/Média Qualidade concentram-se abaixo de 10,2%. Paralelamente, vinhos de Alta Qualidade apresentam um limite rígido de acidez volátil, raramente ultrapassando o valor de 0.55, enquanto os vinhos de menor pontuação exibem acidez volátil dispersa acima de 0.65.

8. CONCLUSÃO E RECOMENDAÇÕES ESTRATÉGICAS

A aplicação de Machine Learning na classificação do Vinho Verde tinto demonstrou ser uma ferramenta de alto valor para a padronização e automação da qualidade na vinícola. A modelagem superou os desafios estatísticos impostos pelo desbalanceamento crítico do dataset por meio de um pipeline estruturado com o RobustScaler e validação cruzada estratificada.

Embora o modelo Gradient Boosting tenha apresentado uma acurácia média de validação cruzada ligeiramente superior (88,45% contra 85,88% do Random Forest), o modelo recomendado para a implantação em produção é o Random Forest. Essa escolha técnica e estratégica de negócio justifica-se pelos seguintes fatores fundamentais:

- **Proteção contra Overfitting:** O Gradient Boosting demonstrou um gap acentuado de mais de 9 pontos percentuais entre treino (97,05%) e teste (87,75%), indicando memorização de ruídos específicos da base de treino. O Random Forest, baseado em amostragem aleatória (bagging), oferece maior estabilidade e menor risco de falhas preditivas em novos lotes de produção.
- **Superioridade nas Métricas de Interesse:** Graças ao `class_weight='balanced'`, o Random Forest alcançou um F1-Score de 49% e Recall de 44% no teste para a classe Premium, superando significativamente o Gradient Boosting, que obteve F1-Score de 42% e Recall de apenas 33%.
- **Prevenção de Falsos Alertas:** O Random Forest registrou apenas 10 Falsos Positivos, minimizando o risco de rotular erroneamente vinhos de menor qualidade como premium, o que protege diretamente a reputação e o valor de marca da vinícola.

Recomendamos, portanto, que a vinícola estabeleça o Random Forest como o gatekeeper digital na linha de envase, atrelado a um controle laboratorial rigoroso que assegure teor alcoólico acima de 11,5% e limite de acidez volátil rigorosamente abaixo de 0,55 para os lotes destinados ao mercado premium.

9. BIBLIOGRAFIA E REFERÊNCIAS TÉCNICAS

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, v. 12, p. 2825-2830, 2011. (Documentação técnica para RobustScaler e estratégias de estratificação).

WINEQT Dataset. Disponível via Kaggle (2024). O pipeline de tratamento incluiu a remoção da coluna id para evitar contaminação de variáveis de indexação no aprendizado.

MCKINNEY, W. Python for Data Analysis. 2. ed. Sebastopol: O'Reilly Media, 2017. (Referência para manipulação, limpeza e tratamento de dados com Pandas).

SCIKIT-LEARN. Classification Metrics Documentation. Disponível em: <scikit-learn.org>. Acesso em: agosto de 2026. (Fundamentação teórica para Precision vs. Recall Trade-offs).